# 사이버보안 에이전트의 반복 샘플링에서 정답 생성과 최빈 답 선택의 간극

신다윗*, 아궁*, 아마다*, 울란*, 함단*, 정회광*, 한승민*, 김호원**

*부산대학교 (대학원생), **부산대학교 (교수)

# The Gap Between Correct-Answer Generation and Modal Answer Selection in Multi-Rollout Cybersecurity Agents

Dawit Shin*, Anak Agung Ngurah Dharmawangsa*, Ahmada Yusril Kadiptya*, Mulyasari Wulan Silvani*, Hamdan Azani*, Hoekwang Jeong*, Seungmin Han*, Howon Kim**

*Pusan National University(Graduate student),

**Pusan National University(Professor)

**요 약**

반복 샘플링의 성능은 정답 후보가 생성된 뒤 실제 출력까지 보존되는지를 기준으로 평가해야 한다. 본 연구는 읽기 전용 정적 사이버보안 과제에서 후보 생성, 최빈 답 선택, 기권을 분리해 분석하였다. Granite 4.2 8B (Q4_K_M)를 CyBench 개발 과제 15개에 과제당 50회 실행했다. 정답 별칭 기준으로 K=5에서 K=25로 늘리자 Oracle 정답 과제는 4개에서 7개로 증가했지만 최빈 답 정답 과제는 3개에서 4개로 증가하는 데 그쳤다. K=50에서는 동일한 오답이 49회, 정답이 1회 생성된 사례가 관찰되었다. 이후 K=20, 최빈 답 비율 0.60의 기권 규칙을 고정하였다. CyBench 미사용 11개에서는 6정답·2오답·3기권을, 외부 35개에서는 2정답·7오답·26기권을 기록했다. 외부 과제의 Oracle도 3/35로, 이 집합에서는 정답 후보 부재가 주요 성능 제약이었다. 이 결과는 반복 횟수뿐 아니라 선택과 기권에서 보존한 정답 수를 함께 보고해야 함을 보여준다.

## I. 서론

대규모 언어 모델(LLM)의 반복 샘플링은 여러 후보를 생성해 정답을 얻을 기회를 늘린다. 자기일관성(self-consistency)은 여러 추론 경로의 공통 답을 선택하며[1], 코드 생성 연구는 정답 후보의 존재를 측정하는 Pass@K와 후보 중 하나를 실제로 반환하는 선택 문제를 구분했다[2]. 사이버보안 에이전트에서도 중요한 것은 생성된 정답이 최종 출력으로 이어지는가이다.

답의 반복 빈도는 선택의 근거이자 신뢰도 신호다. 의미 엔트로피(semantic entropy)는 응답의 의미 분포를 분석하지만[3], 동일한 오답의 반복은 일관성 기반 오류 탐지를 어렵게 한다[4]. 선택적 예측(selective prediction)은 응답 여부를 결정해 응답률과 오류율을 조절한다[5]. 따라서 후보 생성, 답 선택, 기권의 효과를 연결해 평가해야 한다.

본 연구는 정적 사이버보안 과제에서 후보 부재, 선택 손실, 기권에 따른 정답 손실을 구분한다. 기여는 세 가지다. 첫째, 정답 후보의 존재와 문자열 최빈 답 선택을 동일 기준으로 비교한다. 둘째, 의미적 일관성이 높은 오답을 분석한다. 셋째, 고정 정책의 정답 보존과 오답 기권을 미사용·외부 과제에서 평가한다. 전체 절차는 그림 1과 같다.

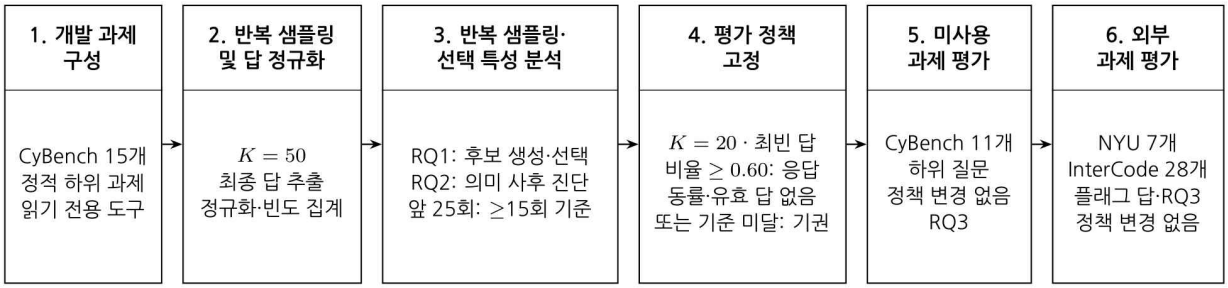



그림 1 연구 전체 수행 흐름. K=25는 앞 25회 재사용, 의미 지표는 사후 진단용

RQ1. K 증가에 따른 정답 후보 생성과 최빈 답 선택의 성능 차이는 어떻게 변하는가?

RQ2. 의미적 일관성은 최빈 답의 정오를 얼마나 구분하며, 높은 일관성의 오답은 어떤 형태로 나타나는가?

RQ3. 고정 기권 규칙은 미사용·외부 과제에서 정답 보존, 오답 기권, 응답률과 응답 오류율에 어떤 영향을 미치는가?

## II. 실험 설계

### 2.1 실험 환경 및 데이터 구성

CyBench[6]에서 정적 파일로 답할 수 있는 개발 하위 과제 15개와 미사용 하위 과제 11개를 사용하였다. 외부 과제는 NYU CTF Bench[7] 7개와 InterCode-CTF[8] 28개다. CyBench는 하위 질문을, 외부 집합은 최종 플래그를 채점한다. 미사용은 이번 연구의 정책 선택에 사용하지 않았다는 뜻이다. 외부 과제는 생성 전에 공개 파일과 질문으로 수행 가능성을 검토해 선정하였다.

모델은 IBM Granite 4.2 8B GGUF (Q4_K_M)[9]이며 RTX 5070, llama.cpp b11026에서 실행하였다. 문맥 길이는 8,192토큰, temperature는 1.0, top-p는 0.95로 고정했다. 한 과제에서 최종 응답을 생성하는 한 번의 실행을 롤아웃(rollout)으로 정의하고, 매 롤아웃의 대화 기록과 도구 상태를 초기화하였다. 시드는 1101×j (j=1,…,K)를 순서대로 사용했다.

도구는 파일 목록·읽기·문자열 추출·16진수 보기에 한정했다. 롤아웃당 도구 호출은 최대 4회, 턴당 생성은 최대 1,024토큰이다. 도구 출력은 건당 4,000자, 누적 5,000자로 제한하였다. 이 제한은 초기 문맥 초과를 수정한 뒤 적용했으며, 재실행한 개발 결과와 K=25·의미 분석은 탐색적 분석으로 구분하였다. 단계별 생성 조건은 표 1과 같다.

표 1 단계별 데이터와 생성 조건

| 단계·과제 | K / 롤아웃 | 생성 설정 |
|---|---|---|
| CyBench 15개 | 50 / 750회 | 초기프롬프트 추론모드 low-effort |
| 앞25회 선택기준 분석 | 25 / 375회재사용 | |
| CyBench 미사용 11개 | 20 / 220회 | prompt v2 추론모드비활성화 |
| 외부 35개 | 20 / 700회 | |

K=50·K=25는 반복 생성과 선택 특성 분석에, K=20은 새 과제에 고정 정책을 적용하는 평가에 사용한다. 생성 설정과 채점 대상이 달라지는 두 단계를 별도로 보고한다.

### 2.2 최빈 답 선택과 기권 규칙

최종 답을 파싱한 뒤 고정된 정규화 규칙을 적용하였다. 규칙에는 유니코드 NFKC, 대소문자 통합, 연속 공백 정리, 주변 인용부호·마크다운 제거가 포함된다. 유효 응답은 최종 답을 파싱할 수 있는 롤아웃이며, 그중 동일한 정규화 문자열의 빈도가 가장 높은 답을 최빈 답(modal answer)으로 선택한다. 개별 롤아웃의 생성과 최빈 답 선택에는 정답표를 사용하지 않았다.

개발 결과와 K=25 분석에서는 동률을 가장 앞선 시드의 답으로 해소하였다. K=25의 기권 규칙은 최빈 답이 15회 이상 나타날 때 응답하는 절대 빈도 기준이다. K=50 정답 별칭 기준의 누적 Oracle에서 마지막 신규 정답 과제는 K=18에 추가되었다. 이후 K=50까지 7/15로 유지된 관찰을 근거로 미사용 평가 전 반복 횟수를 K=20으로 정했다.

K=20에서는 최빈 답이 유일하고, 유효 응답 수 $n_{valid}$중 최빈 답 빈도 $c_{\mathrm{modal}}$의 비율이 0.60 이상이면 응답한다. 동률·유효 응답 부재·기준 미달은 기권(abstention)한다. 최빈 답 비율(modal support)은 다음과 같다. $s = \frac{c_{\mathrm{modal}}}{n_{valid}}$

이 평가 정책은 CyBench 미사용·외부 과제에서 변경 없이 적용하였다.

### 2.3 의미 기반 사후 진단

K=50 응답을 과제별 규칙으로 의미 군집(semantic cluster)에 배정하였다. 군집 규칙은 관찰된 응답으로 구성했다. 단일 주석자가 기준 정답과 공개 파일을 참조해 정오를 판정했으며, 후속 검토는 규칙 기반으로 수행했다. 최빈 의미 군집 비율(semantic modal support)과 경험적 의미 엔트로피(empirical semantic entropy)는 군집 빈도로 계산하였다[3].

$$p_c = \frac{n_c}{n_{valid}}, s_{sem} = \max_c p_c$$

$$H_{sem} = -\sum_{c} p_c \ln p_c$$

두 지표는 반복 응답의 의미적 집중도를 진단한다. 실제 답 선택은 의미 군집을 합치기 전 문자열 빈도로 수행한다. 의미 정오는 정답·오답·모호로 기록하며, 모호 과제는 정답 수에 포함하지 않고 정오 구분 분석에서 제외한다.

2.4 채점 기준과 평가 지표

정답 별칭 기준(strict gold-alias)은 정규화된 답을 사전에 등록한 정답 표현과 비교한다. 사후 의미 기준은 문자열로 선택한 답에 해당하는 의미 주석을 이용한다. 선택은 의미 군집 병합 전의 문자열 빈도를 따른다.

Oracle Pass@K는 고정된 시드 순서의 앞 K개에 정답이 존재하는 과제 비율이다. 조합식 추정량[2] 대신 누적 관찰값을 사용하며, 본문은 과제 수/N, 그림은 과제 수로 보고한다.

표 2 선택·채점·진단의 역할 구분

| 항목 | 계산·역할 |
|---|---|
| Oracle Pass@K | 앞 K개에 정답이 존재하는 과제 비율 |
| 최빈 답 정답수 | 문자열 빈도로 선택한 답을 채점 |
| 최빈 답 비율 s | $\frac{c_{modal}}{n_{valid}}$; K=20 기권 판정 |
| $s_{sem}$, $H_{sem}$ | 의미 군집 분포의 사후 진단 |
| 응답률 · 응답오류율 | 응답 과제/N · 오답 과제/응답 과제 |

K=20은 정답 별칭 기준으로만 채점하였다. 응답률(coverage)과 응답 오류율(selective risk)은 표 2의 과제 단위 분모를 따른다. 정오 구분 AUROC는 정답을 양성으로 두고, 최빈 의미 군집 비율 $s_{sem}$과 음의 경험적 의미 엔트로피 $-H_{sem}$을 신뢰도 점수로 사용한다. 95% 구간은 과제 단위 층화 부트스트랩 결과이며, 반복 롤아웃을 독립 과제로 취급하지 않는다.

## III. 결과 및 분석

3.1 정답 후보 증가와 선택 이득의 차이

정답 별칭 기준에서 K=5에서 K=25로 늘렸을 때 Oracle 정답 과제는 4/15에서 7/15, 최빈 답 정답 과제는 3/15에서 4/15로 증가했다. 선택 성능도 개선되었지만 후보 생성의 증가분을 모두 회수하지는 못했다. K=25에서 15회 이상 기준을 적용하면 7개 과제에 응답하여 3정답·4오답을 기록했다.

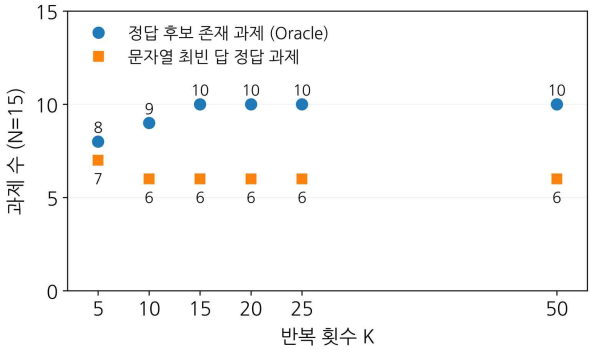



그림 2 K별 정답 후보 존재 과제 수와 문자열 최빈 답 정답 과제 수(사후 의미 채점)

그림 2는 문자열 최빈 답을 먼저 고른 뒤 사후 의미 채점한 결과다. K=5에서 K=15로 증가할 때 Oracle은 8/15에서 10/15, 최빈 답 정답 수는 7/15에서 6/15로 변했다. K=15 이후의 차이 4개는 정답 후보를 포함한 오답 선택 3개와 모호 판정 1개다. 확정된 오답 선택 손실은 이 중 3개다.

3.2 높은 의미적 일관성에서의 오답

K=50의 의미 기준 정오는 6정답·8오답·1모호였다. 오답 8개 중 4개는 최빈 의미 군집 비율이 0.90 이상이었고, 3개는 정답 소수 후보를 포함했다. MOTP에서는 오답 !==가 49회, 정답 ==가 1회 생성되었다. 이 과제는 Oracle에는 정답으로 집계되지만 최빈 답 선택에는 오답으로 집계된다. 동일 오답의 고빈도 반복이 정답 후보를 가린 사례다.

모호 1개를 제외한 14개 과제에서 $s_{sem}$과 $-H_{sem}$의 AUROC는 모두 0.844였다. 95% 구간은 각각 [0.594, 1.000], [0.583, 1.000]이다. 14개 중 12개는 한두 의미 군집이었고, $H_{sem} = 0$인 오답도 1개 있었다.

3.3 후보 부재와 기권에 따른 손실

표 3은 기권 전후의 결과에 Oracle을 함께 제시한다. CyBench 미사용 과제에서는 정답 6개를 보존하면서 오답 3개를 추가로 기권하였다. 응답 오류율은 45.5%에서 25.0%로 낮아졌으며 응답률은 72.7%였다.

표 3 K=20의 후보 생성·선택·기권 결과

| 지표 | CyBench 11개 | 외부 35개 |
|---|---|---|
| 첫 시드 정답 과제 | 5/11 | 2/35 |
| Oracle 정답 과제 | 7/11 | 3/35 |
| 임계값 적용 전 (정답/오답/기권) | 6 / 5 / 0 | 3 / 25 / 7 |
| 임계값 적용 후 (정답/오답/기권) | 6 / 2 / 3 | 2 / 7 / 26 |
| 응답률 (전→ 후) | 100 → 72.7% | 80.0 → 25.7% |
| 응답 오류율 (전→ 후) | 45.5 → 25.0% | 89.3 → 77.8% |
| 무효 롤아웃/ 전체 | 37/220 (16.8%) | 159/700 (22.7%) |

임계값 적용 전에도 동률 또는 유효 응답 부재에 따른 기권은 포함한다.

외부 과제에서는 Oracle과 임계값 적용 전 최빈 답 정답 수가 모두 3/35였다. 정답 후보가 없었던 32개 과제는 고정 후보 선택으로 해결할 수 없다. 임계값은 오답 18개와 정답 1개를 추가 기권시켰지만(표 4), 남은 9개 응답 중 7개가 오답이었다.

표 4 원인별 기권 과제 수

| 평가 집합 | 기존 기권 | 오답 추가 기권 | 정답 추가 기권 |
|---|---|---|---|
| CyBench 11개 | 0 | 3 | 0 |
| 외부35개 | 7 | 18 | 1 |

최빈 답 비율의 분모도 결과 해석에 중요하다. 미사용 과제 중 하나에서는 유효 응답 9개가 모두 같은 오답이고 나머지 11회는 무효였지만, 최빈 답 비율은 9/9=1.0이었다. 따라서 비율과 함께 유효·무효 응답 수를 보고해야 한다.

## IV. 논의 및 한계

반복 샘플링의 이득은 정답 후보의 증가와 최종 출력의 정답 보존을 함께 평가해야 한다. 결과는 후보 부재, 최빈 답 선택 손실, 기권에 따른 정답 손실을 구분하고 응답 오류율을 함께 보고할 근거를 제공한다.

적용 범위는 단일 모델의 정적 과제와 사후 의미 주석이다. 미사용 과제의 사전학습 미노출 여부는 확인되지 않았다. 후속 검증은 여러 모델·과제와 독립 의미 주석으로 확장한다.

## V. 결론

반복 샘플링은 정답 후보를 늘렸지만 최빈 답 선택은 그 이득을 모두 회수하지 못했다. 높은 의미적 일관성에서도 오답이 남았으며, 외부 과제에서는 후보 부재와 기권에 따른 정답 손실이 함께 관찰되었다. 따라서 반복 샘플링 평가는 후보 생성부터 선택과 기권까지의 단계별 정답 보존 수, 응답률, 응답 오류율을 함께 제시해야 한다.

## Acknowledgement

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-대학ICT연구센터(ITRC)의 지원을 받아 수행된 연구임(IITP-2026-RS-2020-II201797)

## [참고문헌]

[1] X. Wang et al., “Self-Consistency Improves Chain of Thought Reasoning in Language Models,” ICLR, 2023.

[2] M. Chen et al., “Evaluating Large Language Models Trained on Code,” arXiv:2107.03374, 2021.

[3] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, “Detecting Hallucinations in Large Language Models Using Semantic Entropy,” Nature, vol. 630, pp. 625 - 630, 2024.

[4] H. Tan et al., “Too Consistent to Detect: A Study of Self-Consistent Errors in LLMs,” EMNLP, 2025.

[5] Y. Geifman and R. El-Yaniv, “SelectiveNet: A Deep Neural Network with an Integrated Reject Option,” ICML, pp. 2151 - 2159, 2019.

[6] A. K. Zhang et al., “CyBench: A Framework for Evaluating Cybersecurity Capabilities and Risks of Language Models,” ICLR, 2025.

[7] M. Shao et al., “NYU CTF Bench: A Scalable Open-Source Benchmark Dataset for Evaluating LLMs in Offensive Security,” NeurIPS, 2024.

[8] J. Yang et al., “InterCode: Standardizing and Benchmarking Interactive Coding with Execution Feedback,” NeurIPS, 2023.

[9] IBM, “Granite 4.2 8B GGUF,” Hugging Face 모델 카드, ibm-granite/granite-4.2-8b-GGUF, 2026.